

Safe-aware дискриминантная коррекция и внутриклассовое отбеливание для быстрых геометрических фильтров детекции jailbreak-атак (семейство RSFI)

Осанов В.А.¹, Лебедев П.Д.¹, Ворфоломеев С.В.¹

¹Поволжский государственный университет телекоммуникаций и информатики (ПГУТИ), 443010, Россия, г. Самара, Московское шоссе, д. 77
e-mail: me@a31di.ru

Аннотация. Работа посвящена сверхбыстрым геометрическим фильтрам первого эшелона (L1) для детекции jailbreak-атак на большие языковые модели в пространстве текстовых эмбеддингов. Показано, что одноклассовые фильтры (наивный косинус, SVD-подпространство) систематически теряют качество на гетерогенных данных, поскольку игнорируют геометрию безопасного класса. Предложены: (1) safe-aware дискриминантная коррекция $B1$ — направление $\mu_{mal} - \mu_{safe}$ (один вектор, $O(d)$ на запрос), дающая прирост +7.7–10.5 п.п. ROC-AUC над наивным косинусом на гетерогенном корпусе WildChat ($p < 0,0001$, парный тест Делонга, 5 сидов, воспроизводится на четырёх эмбеддерах размерности 768–4096); (2) внутриклассовое отбеливание $\Sigma_W^{-1/2}$, для которого доказано точное разложение $\Sigma_T = \Sigma_W + \Sigma_B$ с межклассовой добавкой ранга 1 и формула деградации тотального отбеливания через тождество Шермана–Моррисона; Σ_W -отбеливание восстанавливает в среднем 43,9% потерь тотального отбеливания и не уступает ему ни в одной из 12 конфигураций. Метод $B1$ превосходит опубликованные трансформерные классификаторы ProtectAI DeBERTa-v3 (0,8405) и unitary/toxic-bert (0,7236) на WildChat при задержке скоринга около 0,003 мс против единиц–десятков миллисекунд. Честно зафиксированы границы применимости: статическая обфускация (base64) и адаптивный жадный подбор синонимов (обход при изменении менее 3% слов, коразмерность 1); рекомендована роль ультрабыстрого эшелона L1 в архитектуре defense-in-depth, а не замена нейросетевым судьям. Все числа воспроизводимы из закоммиченных CSV и покрыты 248 автотестами.

Ключевые слова: безопасность больших языковых моделей; jailbreak; prompt injection; эмбеддинги; геометрические фильтры; дискриминантное направление; отбеливание; оценка Ледуа–Вольфа; разложение ковариации; guardrails.

Safe-Aware Discriminant Correction and Pooled Within-Class Whitening for Fast Geometric Filters in LLM Jailbreak Detection (RSFI Family)

Osanov V.A.¹, Lebedev P.D.¹, Vorfolomeev S.V.¹

¹Povolzhskiy State University of Telecommunications and Informatics (PSUTI), 77 Moskovskoe sh., Samara, 443010, Russia
e-mail: me@a31di.ru

Abstract. We study ultrafast first-echelon (L1) geometric filters for jailbreak-attack detection on large language models in text-embedding space. One-class filters (naive cosine, SVD subspace) systematically lose accuracy on heterogeneous data because they ignore the geometry of the safe class. We propose: (1) safe-aware discriminant correction $B1$ — the direction $\mu_{mal} - \mu_{safe}$ (a single vector, $O(d)$ per query), gaining +7.7–10.5 pp ROC-AUC over naive cosine on the heterogeneous WildChat corpus ($p < 0,0001$, paired DeLong test, 5 seeds, reproduced on four embedders of dimension 768–4096); (2) pooled within-class whitening $\Sigma_W^{-1/2}$, for which we prove the exact decomposition $\Sigma_T = \Sigma_W + \Sigma_B$ with a rank-1 between-class term and a total-whitening degradation formula via the Sherman–Morrison identity; Σ_W -whitening recovers on average 43,9% of total-whitening losses and never loses to it in any of 12 configurations. Method $B1$ outperforms published transformer classifiers ProtectAI DeBERTa-v3 (0,8405) and unitary/toxic-bert (0,7236) on WildChat at a scoring latency of about 0,003 ms versus units to tens of milliseconds. Applicability boundaries are honestly reported: static obfuscation (base64) and adaptive greedy synonym substitution (bypass at under 3% word changes, codimension 1); we recommend the role of an ultrafast L1 echelon in a defense-in-depth architecture rather than a replacement for neural judges. All numbers are reproducible from committed CSV files and covered by 248 automated tests.

Keywords: large language model safety; jailbreak; prompt injection; embeddings; geometric filters; discriminant direction; whitening; Ledoit–Wolf estimation; covariance decomposition; guardrails.

1. Введение

Внедрение больших языковых моделей (LLM) в критические корпоративные контуры (финтех, здравоохранение, юридический сектор) упирается в уязвимости к состязательным атакам: jailbreak, инъекции промптов, семантические манипуляции [11, 26]. Зрелые enterprise-решения к 2026 году сошлись к трёхслойной архитектуре защиты («Three-Clocks»): L1 — быстрые геометрические/статистические фильтры эмбеддингов (доли миллисекунды), L2 — специализированные классификаторы (десятки–сотни миллисекунд), L3 — LLM-судьи для асинхронного аудита (секунды). Настоящая работа занимает уровень L1: фильтр, который отсекает очевидные атаки до того, как запрос достигнет дорогих эшелонов L2/L3.

Проблема известных L1-фильтров двояка. Во-первых, одноклассовые методы (косинус до центроида атак, SVD-подпространство угроз) слепы к безопасному классу и деградируют на стилистически гетерогенных данных. Во-вторых, сферическое отбеливание, устраняющее анизотропию эмбеддингов («семантический конус» [3, 2]), помогает не всегда: на гетерогенных корпусах оно вредит разделению, и до настоящей работы причина этого не была формализована.

О названии и рамках. Историческое имя проекта — Riemannian System Fidelity Index (RSFI). Риманов аппарат (логарифмическая и экспоненциальная карты на $\mathbb{S}^{d-1}$) реализован в библиотеке (src/rsfi/geometry.py, класс RiemannianSphere).

и покрыт юнит-тестами, однако бенчмаркированный в работе конвейер использует евклидову сферическую геометрию: L_2 -нормализацию, ZCA-отбеливание Ледуа–Вольфа и SVD/дискриминантные направления. Это разграничение строгое и осознанное; никаких римановых карт в оценённых методах нет.

Вклад работы:

1. Safe-aware дискриминантная коррекция $B1$ (направление $\mu_{mal} - \mu_{safe}$, один вектор, $O(d)$): +7.7–10.5 п.п. ROC-AUC на WildChat, 5/5 сидов, $p < 0,0001$; уровень, близкий к supervised-потолку (логистическая регрессия).
2. Теория внутриклассового отбеливания: точное тождество $\Sigma_T = \Sigma_W + \Sigma_B$, формула подавления сигнала через Шермана–Моррисона, метод $B1w$ ($\Sigma_W^{-1/2}$) со средним восстановлением 43,9% потерь.
3. Прямое сравнение с опубликованными классификаторами на общих сплитах: лёгкий фильтр превосходит DeBERTa-v3 и toxic-bert при задержке на три порядка ниже.
4. Честные границы: обфускация (base64: $B1$ сохраняет 0,705 против 0,238 у наивного косинуса), адаптивный противник (коразмерность 1, обход при $< 3\%$ замен), кросс-доменный перенос и операционные точки (TPR при FPR 1%).

2. Обзор литературы

Геометрия представлений. Анизотропия контекстных эмбеддингов (концентрация в узком конусе, ненулевое среднее) установлена в [3]; отбеливание представлений предложений — в [2]. Риманова оптимизация на многообразиях изложена в [4, 5, 6]. Направление отказа как геометрический объект («refusal is mediated by a single direction») показано в [7]; раздельное кодирование вредоносности и отказа — в [8]. Стриминговая детекция по траекториям скрытых состояний (TrajGuard) [9] и инженерия представлений [10] развивают смежный white-box фланг, тогда как настоящая работа остаётся строго black-box (только эмбеддинги запросов).

Защита LLM. Базовые guardrail-подходы: Llama Guard [11], NeMo Guardrails [12], позиционная статья о guardrails [13], модерационные API. Лёгкие эмбеддинговые защиты (drift detection, steering, codebooks) активно исследуются [14–17]. Отличие настоящей работы: строгий leakage-free протокол с фиксированными сидами, тестами ДеЛонга и автотестами консистентности каждой ячейки отчёта, плюс доказанная теория отбеливания и честно измеренные границы, включая адаптивного осведомлённого противника (в духе [24]).

Данные и метрики. Корпусы: ToxicChat [18] (5082 реальных диалога: 384 вредоносных, 4698 безопасных), WildChat (гетерогенный открытый корпус; рабочая выборка 2000 запросов: 1000/1000), XSTest [19] (450 контрастных омонимических пар: 200 unsafe / 250 safe), AdvBench [20] (520 вредоносных) и HarmBench [21] (400) в паре с 400 безопасными Alpaca [22]. Сравнение ROC-кривых — парный тест ДеЛонга [23]; оценка ковариаций при $N_{ref} \leq d$ — усадка Ледуа–Вольфа [1].

3. Математическая модель

3.1. Латентное пространство как сфера

Пусть $\mathcal{X}$ — множество последовательностей токенов над конечным алфавитом, $E : \mathcal{X} \rightarrow \mathbb{R}^d$ — энкодер ($d \in \{768, 1024, 4096\}$, $d \geq 2$). Нормализация

$$\hat{x} = \frac{E(x)}{\|E(x)\|_2}$$

отображает состояния на единичную гиперсферу

$$\mathcal{M} = \mathbb{S}^{d-1} = \{x \in \mathbb{R}^d : \|x\|_2 = 1\},$$

с геодезическим расстоянием (длиной дуги большой окружности)

$$d_{\mathcal{M}}(x, y) = \arccos\langle x, y \rangle \in [0, \pi].$$

Эмбеддинги естественного языка анизотропны: $\mu = \mathbb{E}[E(x)] \neq \mathbf{0}$ (концентрация в узком конусе). По калибровочному корпусу $\{x_i\}_{i=1}^N$ оцениваются среднее $\hat{\mu}$ и ковариация Σ ; при $N_{ref} \leq d$ вырожденность снимается усадкой Ледуа–Вольфа $\Sigma_{LW} = (1 - \rho)\Sigma + \rho\mu I$, $\mu = \frac{1}{d}\text{Tr}(\Sigma)$, $\rho \in [0, 1]$ оптимален. ZCA-отбеливание $W = \Sigma_{LW}^{-1/2} = V\Lambda^{-1/2}V^T$ с последующей ренормализацией

$$\tilde{x} = \frac{W(x - \mu)}{\|W(x - \mu)\|_2} \in \mathbb{S}^{d-1}$$

выравнивает масштабы дисперсии перед скорингом.

3.2. Дискриминантное направление

Одноклассовый SVD-базис на вредоносных векторах находит направления *внутренней* дисперсии класса угроз, а не разделяющую гиперплоскость. Двухклассовая коррекция использует центры масс обоих классов:

$$\mathbf{w}_{disc} = \frac{\mu_{mal} - \mu_{safe}}{\|\mu_{mal} - \mu_{safe}\|_2}, \quad s_{B1}(x) = \tilde{x}^T \mathbf{w}_{disc},$$

одно скалярное произведение, $O(d)$, один хранимый вектор. Контрастивный SVD $(X_{mal} - \mu_{safe})^T = U_{cont} S_{cont} V_{cont}^T$ — родственное k -мерное обобщение; RSFI-функционал касательного пространства ($\|\mathbf{v}_{\perp}\| - \alpha\pi_{thr} - \beta d_{\mathcal{M}}$, решающее

правило BLOCK при $\text{rsfi} < \tau$) в продакшен-конвенции знака ранг-эквивалентен $B1$ ($|\Delta\text{AUC}| \leq 0,0068$ на всех 9 конфигурациях; в линейном пределе $\alpha \rightarrow \infty, \beta = 0$ эквивалентность точная с отклонением $\leq 6,1 \cdot 10^{-3}$).

3.3. Разложение ковариации и семейство Махаланобис-дискриминантов

Определение 1 (Сферический ZCA-отбеливатель). Для SPD-матрицы $\Sigma = V\Lambda V^T$: $W(\Sigma) = \Sigma^{-1/2}$, $T_\Sigma(x) = W(\Sigma)(x - \mu_\Sigma)$, $\hat{x} = T_\Sigma(x)/\|T_\Sigma(x)\|$.

Предложение 1 (ZCA-коммутация отбеливания и дискриминанта). Направление дискриминанта по отбелённым пулам совпадает с отбелённым дискриминантом исходного пространства: $T_\Sigma(\mu_m) - T_\Sigma(\mu_s) = W(\Sigma)d$, $d = \mu_m - \mu_s$, независимо от весов смеси. Итоговый скор — сферический Махаланобис-косинус $B1_\Sigma(x) = \text{snc}_{\Sigma^{-1}}(x; d)$; семейство $\{B1, B1b, B1w\}$ — один метод с метриками $I, \Sigma_T^{-1}, \Sigma_W^{-1}$.

Теорема 1 (Точное тождество). Для смеси двух классов с весами (π_m, π_s) :

$$\Sigma_T = \Sigma_W + \Sigma_B, \quad \Sigma_B = \pi_m \pi_s dd^T,$$

тотальная ковариация равна пулу внутриклассовых плюс ранг-1 межклассовая добавка вдоль d (закон полной ковариации).

Следствие 1 (Формула деградации). По Шерману–Моррисону:

$$\|d\|_{\Sigma_T^{-1}} = \frac{\|d\|_{\Sigma_W^{-1}}}{\sqrt{1 + \pi_m \pi_s \|d\|_{\Sigma_W^{-1}}^2}}.$$

Отбеливание по Σ_T подавляет именно используемый $B1$ сигнал; потеря растёт с внутриклассовым Махаланобис-расстоянием $r_W = \|d\|_{\Sigma_W^{-1}}$: при $r_W \gg 1$ (гетерогенный режим) тотальное отбеливание разрушительно, при $r_W \lesssim 1$ (анизотропный фон, омонимия) безвредно.

Лемма 1 (Валидность при усадке Ледуа–Вольфа). $\hat{\Sigma} = (1 - \rho)S + \rho V I \succ 0$ п.п. при любом $\rho \leq d$; все тождества выше переносятся на усаженные оценки; при $\rho \rightarrow 1$ метрика непрерывно деградирует к изотропной, т.е. $B1w \rightarrow B1$ без ложной геометрии.

Численная верификация на закоммиченных кэшах: тождество $\Sigma_T = \Sigma_W + \Sigma_B$ с относительной точностью следа 10^{-9} – 10^{-8} ; ошибка Шермана–Моррисона 0,05–0,11 (мера рассинхронизации усадки между T - и W -путями, качественный вывод не затрагивает).

4. Методология экспериментов

Протокол. Строгий leakage-free holdout: вся калибровка (средние, ковариации Ледуа–Вольфа, ZCA, SVD-базис, пороги) — только на референсной выборке; тест изолирован через разность множеств. Бюджет: $N_{ref} = 200$ на класс (суммарно 400) для Wild/ToxicChat; для XSTest (200 unsafe/250 safe) — $\lfloor N_{class}/3 \rfloor$: $N_{ref}^{mal} = 66$, $N_{ref}^{safe} = 83$, тест $134 + 167 = 301$. Пять фиксированных сидов (0–4); сравнения — парный тест ДеЛонга (средняя разница AUC, победы по сидам, p -value). Каждая ячейка отчёта пересчитывается автотестом `tests/test_report_consistency.py`; всего **248 автотестов** (консистентность + RSFI + юнит-тесты геометрии/отбеливания/фильтра), все зелёные.

Методы. A1 наивный косинус (raw); A1b косинус после Σ_T -отбеливания; A2 RSFI-SVD ($k = 20$, raw); A3 SVD после отбеливания; B1 дискриминантное среднее (raw); B1b дискриминант после Σ_T -отбеливания; B1w дискриминант после Σ_W -отбеливания (пул внутриклассовых ковариаций, центрирование общим референсным средним); C1 логистическая регрессия (supervised-потолок), C1b её отбелённая версия; 1-классовый и 2-классовый k -NN (среднее топ-5 косинусов); внешние zero-shot классификаторы ProtectAI DeBERTa-v3-prompt-injection-v2 и unitary/toxic-bert на тех же сплитах.

Эмбеддеры. all-mpnet-base-v2 ($d = 768$), BAAI/bge-base-en-v1.5 ($d = 768$), BAAI/bge-large-en-v1.5 ($d = 1024$), Qwen/Qwen3-Embedding-8B ($d = 4096$).

5. Результаты

5.1. Гетерогенный режим: доминирует safe-aware поправка

На WildChat (табл. 1) $B1$ даёт +8.2 п.п. (mpnet), +9.1 п.п. (bge-base), +10.5 п.п. (bge-large) над наивным косинусом, 5/5 сидов, $p < 0,0001$; на Qwen3-8B: $B1 = 0,8747$ против $A1 = 0,7982$. Разрыв до логистической регрессии — около одного пункта (0,8668 против 0,8766 на mpnet).

Таблица 1. WildChat: ROC-AUC, $N_{ref} = 200$ на класс, 5 сидов, mean $\pm$ std.

Модель	A1	A2 (SVD)	B1	C1 (LogReg)
mpnet-base	0,7846 $\pm$ 0,0047	0,7875 $\pm$ 0,0074	0,8668 $\pm$ 0,0060	0,8766 $\pm$ 0,0071
bge-base	0,7708 $\pm$ 0,0040	0,7854 $\pm$ 0,0114	0,8618 $\pm$ 0,0050	0,8728 $\pm$ 0,0038
bge-large	0,7674 $\pm$ 0,0065	0,7839 $\pm$ 0,0110	0,8719 $\pm$ 0,0050	0,8804 $\pm$ 0,0028
Qwen3-8B	0,7982 $\pm$ 0,0102	0,8012 $\pm$ 0,0130	0,8747 $\pm$ 0,0090	0,8847 $\pm$ 0,0083

5.2. Разделение эффектов: режимы решают всё

Полная картина (табл. 2, 4 эмбеддера $\times$ 3 датасета): на омонимическом XSTest весь прирост даёт отбеливание ($A1b = 0,8973 \approx B1b = 0,8970$, $\Delta = -0,0003$, $p = 0,2819$ — safe-aware незначим); на Wild — наоборот, safe-aware в сыром пространстве, а тотальное отбеливание вредит ($0,8668 \rightarrow 0,8297$ на mpnet); на гомогенном ToxicChat работают оба механизма, причём $B1b$ превосходит отбелённую LogReg ($0,9617$ против $0,9581$, $p = 0,0055$).

Таблица 2. ROC-AUC по режимам (среднее 5 сидов; фрагмент: mpnet и Qwen3-8B).

Датасет	Модель	A1	B1	$B1b(\Sigma_T)$	$B1w(\Sigma_W)$
ToxicChat	mpnet	0,9158	0,9509	0,9617	0,9680
	Qwen3-8B	0,8082	0,9628	0,9679	0,9716
Wild	mpnet	0,7846	0,8668	0,8297	0,8475
	Qwen3-8B	0,7982	0,8747	0,8224	0,8391
XSTest	mpnet	0,7618	0,7851	0,8970	0,8999
	Qwen3-8B	0,7824	0,8269	0,9381	0,9370

5.3. Внутрикласовое отбеливание

$B1w \geq B1b$ в 11 из 12 конфигураций; единственное исключение — XSTest $\times$ Qwen3-8B ($0,9370$ против $0,9381$, $|\Delta| = 0,0011$ в пределах per-seed std $0,0115$). Восстановление потерь на Wild: 48,0% (mpnet), 56,4% (bge-base), 39,3% (bge-large), 31,9% (Qwen3-8B) — в среднем **43,9%**; превосходство на Wild значимо 5/5 сидов у всех эмбеддеров. На ToxicChat $B1w$ достигает $0,9680$ – $0,9716$, на XSTest — $0,8999$ – $0,9370$.

5.4. Сравнение с k -NN и внешними классификаторами

Направление $B1$ хранит ровно один вектор ($O(d)$, замер: косинусный скор $\approx 0,003$ мс) против $O(N_{ref} \cdot d)$ у k -NN ($\approx 0,005$ мс): на ToxicChat $B1b$ обходит оба k -NN на всех эмбеддерах; на Wild 2-классовый k -NN сильнее сырого $B1$ на $+0,007$ – $0,011$ AUC ценой 400-векторного индекса; на XSTest оба k -NN проигрывают отбелённому дискриминанту ($0,84$ против $0,90$ на mpnet). Внешние классификаторы на общих сплитах (табл. 3): $B1$ превосходит оба на всех трёх датасетах, включая Wild ($0,8668$ против $0,8405$ у DeBERTa-v3) при задержке на три порядка ниже (скоринг DeBERTa — единицы–десятки мс против $\approx 0,003$ мс). Оговорка честности: обе внешние модели обучены не на джейлбрейках (prompt-injection и гражданская токсичность) и взяты zero-shot без дообучения; вопрос — «конкурентоспособен ли лёгкий фильтр с готовым классификатором», а не «лучший детектор в принципе». Симптом доменной несовместимости: DeBERTa-v3 на XSTest даёт AUC ниже случайного ($0,4022$) — инвертированный сигнал на омонимии, где отбеливание корректно даёт $0,90$.

Таблица 3. Внешние классификаторы: ROC-AUC на общих сплитах, 5 сидов.

Датасет	DeBERTa-v3	toxic-bert	$B1$	$B1b$
ToxicChat	$0,5698 \pm 0,0100$	$0,7934 \pm 0,0126$	$0,9509 \pm 0,0048$	$0,9617 \pm 0,0020$
Wild	$0,8405 \pm 0,0036$	$0,7236 \pm 0,0087$	$0,8668 \pm 0,0060$	$0,8297 \pm 0,0090$
XSTest	$0,4022 \pm 0,0123$	$0,6416 \pm 0,0178$	$0,7851 \pm 0,0203$	$0,8970 \pm 0,0132$

5.5. Кросс-домен, операционные точки, E11

Кросс-доменный перенос (train на одном датасете из пяти, тест на остальных, 4 эмбеддера $\times$ 5 сидов): $B1$ — лучший метод и in-domain ($0,957$), и в переносе ($0,783$); полный отбеливающий конвейер $B1b$ в переносе не лучше сырого косинуса ($0,748$ против $0,754$) — отбеливание требует доменной рекалибровки. Диагональ in-domain после устранения найденной при аудите утечки (перекрытие test/ref давало артефакт $\approx 0,999$) честна и независимо совпала с E14. Операционные точки на AdvBench/HarmBench: на HarmBench наивный косинус непригоден (TPR@FPR1% $\approx 0,32$, FPR@TPR90 до $0,46$), а семейство $B1$ даёт TPR@FPR1% $0,86$ – $0,996$ при FPR@TPR90 $\approx 0,00$ – $0,03$ (напр., bge-large $B1w$: AUC $0,9989$, TPR@FPR1% $0,979$). Валидация RSFI в касательном пространстве (E11): см. раздел 3; калибровка порога — по валидационному safe-пулу.

6. Границы применимости

6.1. Статическая обфускация (E6b)

Калибровка — только на чистых атаках; тест — base64/leetspeak/ROT13/zero-width/homoglyph. Иерархия деградации на Wild при base64 (по трём эмбеддерам): $A1$ $-0,516$, $A2$ $-0,574$ (семейство разрушено полностью), сырой $B1$ $-0,177$ — самый устойчивый из геометрических, сопоставим с supervised-потолком $C1$ ($-0,173$); абсолютный уровень: $B1$ $0,705$ против $0,238$ у наивного косинуса (mpnet). Тип обфускации меняет оптимальную предобработку (под leetspeak лучше отбелённые варианты, под base64 — сырой $B1$); единой конфигурации нет. Zero-width — по-ор для рассмотренных стеков (максимальное отклонение $1,1 \cdot 10^{-4}$, токенизаторы нормализуют ZWSP). XSTest — худший случай: все методы падают до $\leq 0,61$. Вывод: граница относится ко всему эмбеддинг-конвейеру (потолок $C1$ теряет столько же), закрывается L1-декодером (unwrapper) перед эмбеддингом.

6.2. Внешние модели под обфускацией (E9b)

Рост их AUC под трансформациями (до $0,90$ – $1,00$) — OOD-артефакт («аномальные токены $\Rightarrow$ инъекция»), а не робастность; фиксируем как артефакт измерения.

6.3. Адаптивный осведомлённый противник (E6c)

Линейный guardrail $B1(x) = \langle \tilde{e}(x), \mathbf{w}_{disc} \rangle$ имеет коразмерность 1 ($d - 1$ степеней свободы у противника). Жадная замена синонимов против $B1$ обходит его при изменении **0,5%** слов на Wild (ASR@1%FPR $98,3\%$), $2,9\%$ на ToxicChat ($72,0\%$), $4,5\%$ на XSTest ($81,7\%$). Атака не переносится на $B1w$ (ASR $49,7\%$ / $7,0\%$ / $2,0\%$) и на внешние

нейросетевые модели (DeBERTa-v3 сохраняет AUC 0,85). Причина — рассинхронизация градиентов: $\nabla s_{B1} \propto \mathbf{w}_{raw}$, $\nabla s_{B1w} \propto \Sigma_W^{-1} \mathbf{w}_{raw}$, косинус между ними $\approx 0,58$ (угол $\approx 54,4^\circ$). Прямая атака на сам $B1w$ его обходит (ASR 90,3% Wild, 25,0% ToxicChat), подтверждая общность ограничения коразмерности 1: Σ_W -отбеливание защищает от переноса суррогатного градиента, но не от осведомлённого таргетирования.

7. Обсуждение и рекомендации

Универсальное правило предобработки: при наличии двух классов калибровать отбеливание по пулу внутриклассовой ковариации Σ_W , а не по объединённой Σ_T (Σ_W не уступила Σ_T ни в одной из 12 конфигураций). Доменно-агностичный бейзлайн по умолчанию — сырой $B1$ (лучший и in-domain, и в переносе). Рекомендуемая роль: ультрабыстрый эшелон L1 в defense-in-depth (L1 Unwrapper $\rightarrow$ L2 Geometric Pre-filter $\rightarrow$ L3 LLM-Judge/Classifier), отсекающий 17–33% атак при $FPR \leq 1\%$ без задержки инференса; полная стоимость пайплайна определяется эмбеддером (локальный ONNX — 5–10 мс, удалённый API — 100–300 мс), сам скоринг — микросекунды. Для уровня ВАК К1/Q1 потребуется сквозное продакшен-тестирование в связке с генеративными судьями (Llama Guard 3, ShieldLM) — фиксируем как открытую работу, а не как заявку.

8. Заключение

1. Одноклассовые геометрические фильтры теряют качество из-за игнорирования безопасного класса; дискриминант $\mu_{mal} - \mu_{safe}$ закрывает разрыв (+7.7–10.5 п.п. на Wild, $p < 0,0001$), достигая уровня supervised-потолка при одном векторе и $O(d)$.
2. Доказано разложение $\Sigma_T = \Sigma_W + \Sigma_B$ и формула подавления сигнала; Σ_W -отбеливание восстанавливает в среднем 43,9% потерь и не уступает Σ_T нигде.
3. Лёгкий фильтр превосходит опубликованные трансформерные классификаторы на общих сплитах при задержке на три порядка ниже.
4. Границы зафиксированы честно: base64, адаптивный противник с коразмерностью 1, доменная чувствительность отбеливания — с конструктивными закрытиями (unwrapper, рекалибровка, defense-in-depth).

Список литературы / References

1. Ledoit O., Wolf M. A well-conditioned estimator for large-dimensional covariance matrices. *J. Multivariate Analysis*, 2004, 88: 365–411.
2. Su J. et al. Whitening sentence representations for better semantics and faster retrieval. *Proc. ACL*, 2021.
3. Ethayarajh K. How contextual are contextualized word representations? *Proc. EMNLP*, 2019.
4. Absil P.-A. et al. *Optimization Algorithms on Matrix Manifolds*. Princeton Univ. Press, 2008.
5. Boumal N. *An Introduction to Optimization on Smooth Manifolds*. Cambridge Univ. Press, 2023.
6. Lee J. M. *Introduction to Riemannian Manifolds*. Springer, 2018.
7. Arditì A. et al. Refusal in language models is mediated by a single direction. *Proc. NeurIPS*, 2024.
8. Zhao Y. et al. LLMs encode harmfulness and refusal separately. *Proc. NeurIPS*, 2025.
9. Liu C. et al. TrajGuard: streaming hidden-state trajectory detection. *Findings of ACL*, 2026.
10. Zou A. et al. Representation engineering: a top-down approach to AI transparency. *arXiv:2310.01405*, 2023.
11. Inan H. et al. Llama Guard: LLM-based input-output safeguard. *arXiv:2312.06674*, 2023.
12. Reuter D. et al. NeMo Guardrails. *Proc. EMNLP*, 2023.
13. Dong Y. et al. Building guardrails for large language models: a position paper. *Proc. ICML*, 2024.
14. Sekar A. et al. Zero-shot embedding drift detection. *NeurIPS Lock-LLM Workshop*, 2025.
15. Alanova S. et al. Cross-lingual jailbreak detection via semantic codebooks. *arXiv:2604.25716*, 2026.
16. Han P. et al. SafeSwitch: steering unsafe LLM behavior. *Proc. EMNLP*, 2025.
17. He Z. et al. Interpretable LLM guardrails via sparse representation steering. *arXiv:2503.16851*, 2025.
18. Lin Z. et al. ToxicChat: unveiling hidden challenges of toxicity detection. *Findings of EMNLP*, 2023.
19. Röttger P. et al. XSTest: a test suite for identifying exaggerated safety behaviours. *Proc. NAACL*, 2024.
20. Zou A. et al. Improving alignment and robustness with circuit breakers. *arXiv:2307.15043*, 2023.
21. Mazeika M. et al. HarmBench. *arXiv:2402.05793*, 2024.
22. Taori R. et al. Stanford Alpaca. GitHub, 2023.
23. Sun X., Xu W. Fast implementation of DeLong’s algorithm. *IEEE Signal Proc. Lett.*, 2014.
24. Athalye A. et al. Obfuscated gradients give a false sense of security. *Proc. ICML*, 2018.
25. Reimers N., Gurevych I. Sentence-BERT. *Proc. EMNLP*, 2019.
26. Perez F., Ribeiro I. Ignore this title and hack this review. *arXiv:2211.09527*, 2022.